龚舒凯

电话: (+86) 15721022905 | 邮箱: shukai_gong@ruc.edu.cn | 微信号: 15721022905 | 个人主页 | 领英主页

教育背景

中国人民大学 数据科学与大数据-经济学双学士学位, **GPA: 3.90/4.00**, **排名: 1** *2022.09– 2026.06*

加州大学伯克利分校 2024 春季学期交换生, **GPA: 4.00/4.00** *2024.01 – 2024.05*

- **核心课程:** 数学分析 I(4.0)、数学分析 II(4.0)、数学分析 III(4.0)，高等代数 I(4.0)、高等代数 II(4.0), 概率论 (4.0), 数理统计 (伯克利全班第一, A+), 最优化算法 (4.0), 计量经济学 (伯克利全班第一, A+), 随机过程 (4.0), 程序设计 (4.0), 数据结构与算法 (4.0), 数据科学概论 (4.0), 深度学习 (4.0), 多模态机器学习 (4.0), 大数据并行计算 (4.0)
- **编程能力:** 掌握 Python、C/C++、Matlab、R、LaTeX 等编程语言；熟悉 Pytorch 等主流深度学习框架和 Numpy 等常用库；熟悉 Wandb、Hydra 等深度学习工作流优化工具；了解 CUDA 等深度学习底层开发组件及 GPU 编程
- **语言能力:** 四级 659, 六级 613, 雅思 7.5 (听力 8.0, 阅读 8.5, 写作 7.0) ，有独立进行学术写作、投稿和审稿能力
- **在校荣誉:** 中国人民大学特等奖学金 (京东奖学金)、优秀班团骨干奖学金、优秀学生干部称号、三好学生称号

科研经历

[已中稿] USPTO-LLM: 由 LLM 辅助构建的信息增强化学反应数据集 收录于WWW 2025 | 共同一作

- **研究方向**: AI4Science, LLM, 图机器学习
- **研究背景**: 近年来，深度学习模型在化学合成与逆合成领域取得了令人瞩目的成果，但该领域的现有数据集面临两个主要挑战：**数据规模有限**和**反应条件信息缺失**。这限制了模型的泛化能力与对反应条件的关联分析能力，降低了模型的现实可用性。从实践角度看，人工标注大量化学反应的复杂条件不仅成本高昂，而且耗时巨大。因此，亟需**开发一种自动化、高效且可靠的数据构建方法**，以创建包含丰富反应条件信息的大规模化学反应数据集。
- **研究方法**: 首先，我构建出一套数据标注管线，利用大模型 API 从美国专利商标局 (USPTO) 的化学反应专利文档中提取出以异质图组织的有机化学反应。我自主提出**基于 CoT 的 "二轮筛选方法" 和基于正则表达式的 "模式串匹配修复"** 对大模型输出进行后处理，使得 API 的生成准确率提升了 5.7% 至 23.4%。在使用 RdKit 和 RxnMapper 等化学软件包验证数据集的正确性后，我构建出**首个包含反应条件信息的 247K 数据集 USPTO-LLM**。接着，我选取了基于图和基于序列的逆合成预测模型 HGAR 和 Augmented Transformer，设计了两项任务对数据集进行评估: (1) 使用 USPTO-LLM 作为预训练数据集，基于 USPTO-50k 数据集进行全量微调；(2) 直接在 USPTO-LLM 数据集上进行逆合成预测。发现 (a) 在 USPTO-LLM 上预训练的、基于序列的逆合成预测模型表现显著提升。(b) 融入反应条件信息后，基于图和基于序列的逆合成预测模型的逆合成准确率均显著提高。这验证了数据集的有效性。
- **作为共同第一作者 (贡献相等) 独立完成方案细化、数据集构建、实验设计与执行; 相关数据集已获 259 下载量。**

[进行中] 利用推测解码加速基于 Transformer 的深度点过程采样 预计投稿 NeurIPS 2025 | 第一作者

- **研究方向**: 深度点过程, LLM, 推测解码, 加速采样
- **研究背景**: 深度点过程是在连续事件频域建模离散事件的重要工具，其仿真采样可用于分析未来事件规律、验证模型拟合和生成大规模数据。近年来，基于 Transformer 的深度点过程研究主要集中在提升模型的拟合能力上，**但对仿真采样效率提升的关注不足**。当前采样方法通常使用 **Thinning Algorithm**，然而这一算法在生成候选时间戳时需要通过 Transformer 进行一次前向传播来计算条件强度函数和接受率，且生成的时间戳容易被拒绝，**造成效率低下**。
- **研究方法**: 我们将近年来大语言模型领域新兴的**推测解码**引入深度点过程的建模，在维持深度点过程采样质量的同时加快采样速度。具体而言，我们设计了一种新的基于 Transformer 的点过程模型，建模时间戳间隔的**条件概率密度**而非时间戳的条件强度函数。这一设计便于生成候选时间戳间隔，且更容易将推测解码框架融入点过程采样。我们设置小参数量的 Transformer 点过程模型为 Draft 模型，大参数量的 Transformer 点过程模型为 Target 模型，使用 Draft 模型生成候选时间戳间隔，并用 Target 模型计算候选时间戳间隔的对数似然，基于**拒绝采样**思想计算候选时间戳间隔的接受率，从而实现只用 Target 模型的一次前向传播就能生成多个时间戳。我们验证了使用推测解码加速的 Target 模型采样出的点的分布与只用 Target 模型采样出的点的分布相近，且实现了理想的**加速比**。
- **已完成推测解码和深度点过程的详尽文献调研和采样算法设计，实验已在合成和现实数据集上呈现初步进展。**

实习经历

直观复星医疗器械技术有限公司 研发部 算法实习生

- **项目 1：基于 OCR 的参数提取系统**。利用 OCR 实时提取达芬奇手术机器人换能器屏幕上的运行参数。通过高频截取换能器工作时的运行视频帧，并利用 OpenCV 对截取帧进行图像预处理，减少屏幕上参数跳动对识别带来的干扰，将 OCR 的提取准确率提升至 99%。实现过程中，使用多进程分发任务和 GPU 并行加速将该 OCR 识别效率提升 5.3 倍。数据处理阶段，通过计算滑动窗口内参数的均值和标准差筛除异常值，最终将提取的参数实时可视化。**该系统已上线直观医疗电子实验室，显著降低测试工程师的数据记录负担和设备监控负担**。
- **项目 2：售后信息分类系统**。使用 KeyBERT 从 2100 条平均长度为 600 词的达芬奇手术机器人售后反馈中提取出关键信息并归纳为 11 类。使用 6 种 LLM API 对部分售后数据进行标注，用于 SFT 训练。自主构建了一个基于交叉注意力的 Transformer 文本分类模型，让原始文本和 KeyBERT 提取的关键词信息进行交互，使得模型在测试集上达到 97% 的 top-3 归类准确率。**该模型已被直观医疗售后工程师采纳，用于辅助快速定位问题**。

项目实践

遥感数据驱动的地区经济发展评估与政策决策支持模型 |*PDF* | *Github* 《大数据并行计算》优秀课设 (96)

- 借助微软的 Planetary Computer API，**多进程爬取** 2021 年至 2024 年四川省 60 个区块的高清卫星遥感图像。将每个区块的卫星图像平均划分为 32×32 个部分，构建出 60K 大小的细粒度四川卫星图像数据集。
- **异步高并发**调用 VLLM API 对 900 张遥感图像进行标注，并用标注数据训练一个 CLIP 分类器，将原始数据集分为城市、农村、山区、高原四类。再对每个类别内的图像使用 DeepCluster 作聚类，最终获得 23 个图像聚类。
- 对 23 个聚类的发展水平进行排序，并基于该排序为聚类内图像数据赋予伪标签，训练一个打分模型对指定卫星图像经济发展水平进行打分。利用 **PyCuda 编写定制化 GPU 核函数**实现 60 区块经济得分图的高效拼接，最终生成四川省高分辨率经济发展水平数字地图。打分模型**在 OOD 数据上也表现出优秀泛化能力**，能为未见地形准确打分。

基于多种多模态融合方式的图生文与文生图模型 | *PDF* | *GitHub* 《多模态机器学习》最优课设 (98)

- 使用 ResNet/CLIP 编码图像，Transformer Decoder 生成文本，交叉注意力机制对齐图像和文本模态，实现了一个简单的基线图生文模型。再用 CLIP 编码图像，Qformer 对齐图像和文本模态，**赋予纯文本语言模型 TinyLlama 图像理解能力**，实现了一个显著优于基线模型的图生文模型，在 Flickr8k 数据集上测试得 BLEU= 0.26。
- 从零搭建了 **Latent Diffusion Model**，调用预训练的 CLIP 编码文本，**自主实现并训练了** LDM 中用于生成隐空间表示的 **VQVAE** 模块和用于去噪的 **U-Net** 模块，作为基线文生图模型。接着以 rank=128 LoRA 微调 SDXL 和 Infinity，实现了两个显著优于基线模型的文生图模型，在 Flickr8k 数据集上测试分别得到 FID=17.29 和 19.73。

竞赛荣誉

国家级立项 & 最佳创意奖 | 中国人民大学“大学生创业训练计划” 2024 年 6 月

一等奖 | 全国大学生数学建模竞赛 *(北京赛区)* 2023 年 11 月

Meritorious Winner | 美国大学生数学建模竞赛 *(MCM/ICM)* 2023 年 5 月

社会活动

特邀讲座：《拥抱大模型：大模型 API 调用、本地配置与相关应用》 *2025.3.6*

- 受中国人民大学应用经济学院邀请，向到场超过 60 名师生介绍 **LLM API 的标准工作流**，以及使用 API 进行文本挖掘和数据标注的案例；讲述安全的**本地配置大模型**的方法，并介绍使用 RAG 构建本地文献阅读助手的案例。